

高级计量暑期班 (Seminar of Advanced Econometrics)

胡华平

西北农林科技大学

经济管理学院数量经济教研室

huhuaping01@hotmail.com

2022-06-28

西北农林科技大学

RDD PART 01 : 非参数估计

1. 均值估计 (Means Estimator)

2. 局部回归 (Local Regression)

3. 估计效果 (Performance Analysis)

4. 群组分析 (Cluster observations)

1. 均值估计 (Means Estimator)

1.1 箱组均值估计 (Binned Means Estimator)

1.2 滚动箱组均值估计 (Rolling Binned Means Estimator)

1.3 核估计 (Kernel Estimator)

(引子)为什么要进行均值估计?

对于计量模型:

$$Y = m(X) + e$$

研究者首先需要关注的是

- 条件期望函数 (Conditional Expectation Function ,CEF) :

$$\mathbb{E}[Y|X = x] \equiv m(x)$$

- 此时:

$$\begin{aligned} Y &= m(X) + e \\ &= \mathbb{E}[Y|X = x] + e \end{aligned}$$

(引子) 什么是非参数估计?

- 理论上, 条件期望函数 $m(x)$ 可以表现为明确的参数化形式 (parametric function), 也可以表现为任意的非参数化形式 (non-parametric function)。

- 常见的参数化条件期望函数, 例如线性形式:

$$Y = m(x) + e = \beta_0 + \beta_1 X + e$$



(引子) 什么是非参数估计?

- 非参数回归模型 (nonparametric regression model) : 假定条件期望函数表现为任意的非参数化形式的回归模型。

- 非参数回归模型可以表达为:



$$Y = \mathbb{E}(Y|X = x) + e = m(x) + e$$

$$\mathbb{E}(e|X = x) = 0$$

$$\mathbb{E}(e^2|X = x) = \sigma^2(X)$$

- 此时, 我们的目标就是估计得到条件期望函数 $\widehat{m}(x)$ 。

(示例) 模拟数据集

为了更好地进行数据验证，我们将根据如下规则生成蒙特卡洛模拟数据集：

$$Y_i = m(X) + e_i = \frac{\sin(\frac{\pi}{4} \cdot (X_i - 2))}{\frac{\pi}{4} \cdot (X_i - 2)} + e_i$$

$$X_i \sim U(0, 10)$$

$$e_i \sim N(0, 2)$$

$$n = 100$$

- 此时，我们具有上帝视角，实际上已经知道数据生成机制（DGP）
- 此时，我们心里面已知真实模型为非线性的

(示例) 模拟的样本数据集

模拟的样本数据集($n=100$)

index	X	Y
1	2.9060	0.8120
2	8.4993	-0.4883
3	6.7846	-0.0454
4	3.2569	1.0822
5	8.8766	-0.4881
6	0.9354	1.1109
7	4.4082	0.2456
8	3.8783	0.9625

Showing 1 to 8 of 100 entries

Previous

1

2

3

4

5

...


13

Next

- 样本数据的描述性统计如下：

index	X	Y
Min.	1	Min. :0.1
1st Qu.	26	1st Qu.:2.3
Median	50	Median :4.6
Mean	50	Mean :4.9
3rd Qu.	75	3rd Qu.:7.5
Max.	100	Max. :9.9

(示例) 样本数据散点图



西北农林科技大学
NORTHWEST A&F UNIVERSITY

1.1 箱组均值估计：表达式

对于非参数模型：

$$Y = \mathbb{E}(Y|X = x) + e = m(x) + e$$

我们可以直接把数据集划分为不同箱组（bins），然后简单地计算各个箱组中 Y_i 的均值。

$$\hat{m}(x) = \frac{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\} \cdot Y_i}{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\}}$$

其中：

- $\mathbf{1}\{|X_i - x| \leq h\}$ 为指示函数，取值为 $\{0, 1\}$ ，以表明 X_i 是否落在特定箱组内
- 以上公式可以简单视作为箱组内的简单算数平均数公式

1.1 箱组均值估计：操作步骤

箱组均值估计（Binned Estimator）的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定谱宽 h , 划分出若干箱组（bins）：

$$\{b_1, b_2, \dots, b_q\}$$

$$b_j = [x_j - h, x_j + h]$$

- 根据样本数据集, 以及 X_i 的实际情况, 确定数据对 $\{X_i, Y_i\}$ 的箱组归属:

$$1 \{ |X_i - x_j| \leq h \}$$

- 最后计算不同箱组的 Y_i 的均值 $\hat{m}(x_{b_j}), j \in (1, 2, \dots, q)$:

$$\hat{m}(x) = \frac{\sum_{i=1}^n 1 \{ |X_i - x| \leq h \} \cdot Y_i}{\sum_{i=1}^n 1 \{ |X_i - x| \leq h \}}$$

(示例) 箱组均值估计：设定箱组划分规则

下面我们分别设定如下箱组划分规则：

- 设定箱组取值中心点 ($X = x_i$), $x_i \in (1, 3, 5, 7, 9)$, 以及谱宽 $h = 1$
- 然后得到箱组区块bins=[0,2)、[2,4)、[4,6)、[6,8)、[8,10]，箱组数为5。

(示例) 箱组均值估计：数据计算表


利用箱组均值估计公式，我们可以计算得到不同箱组的均值估计：

x	bins	sum_ky	sum_k	m0
1	[0,2)	17.4392	20	0.8720
3	[2,4)	20.2144	23	0.8789
5	[4,6)	4.2950	15	0.2863
7	[6,8)	-2.2950	22	-0.1043
9	[8,10]	-1.9965	20	-0.0998

- 箱组内因变量观测值的求和 $\text{sum_ky} = \sum_{i=1}^n 1\{|X_i - x| \leq h\} \cdot Y_i$
- 箱组的样本数 $\text{sum_k} = \sum_{i=1}^n 1\{|X_i - x| \leq h\}$
- 箱组的均值估计 $m0 = \widehat{m}(x_j), j \in (1, 2, \dots, 5)$

(示例) 箱组均值估计：图形表达 1/3


- 首先我们展示的是5个箱组的划分：



说明：a) 垂直虚线表示箱组中心取值点 x_j ；b) 不同矩形颜色区块表示不同箱组。


(示例) 箱组均值估计：图形表达2/3

- 根据箱组均值计算值，我们展示在散点图中：



(示例) 箱组均值估计：图形表达3/3

- 简单地，可将箱组均值作为对这一箱组条件期望函数CEF的近似：



1.2 滚动箱组均值估计：定义及表达式

滚动箱组均值估 (The rolling binned means estimator) : 以系列数值 x 为中心, 以 h 为谱宽, 滚动构建一系列箱组 (箱组会有重叠), 并分别计算出系列箱组的均值。

$$\hat{m}(x) = \frac{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\} \cdot Y_i}{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\}}$$



- 我们后面马上会介绍, 滚动箱组均值估实际上是一类特殊的核估计 (kernel) 情形, 具体为Nadaraya-Watson 矩形和估计 (NW rectangular kernel estimator) 。

1.2 滚动箱组均值估计：操作过程

滚动箱组均值估计（Rolling Binned Estimator）的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定谱宽 h , 划分出若干箱组（bins）（箱组会有重叠）: $\{b_1, b_2, \dots, b_q\}$

$$b_j = [x_j - h, x_j + h]$$

- 根据样本数据集, 以及 X_i 的实际情况, 确定数据对 $\{X_i, Y_i\}$ 的箱组归属:

$$\mathbf{1}\{|X_i - x_j| \leq h\}$$

- 最后计算不同箱组的 Y_i 的均值 $\widehat{m}(x_{b_j}), j \in (1, 2, \dots, q)$:

$$\widehat{m}(x) = \frac{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\} \cdot Y_i}{\sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\}}$$

(示例) 滚动箱组均值估计：设定箱组划分规则

下面我们分别设定如下箱组划分规则：

- 设定箱组取值中心点

$(X = x_i), x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots, 9.95, 9.96, 9.97, 9.98, 9.99, 10.00)$,

以及谱宽^a $h = 1$

- 那么，可以得到箱组区块bins=[-1,1)、[-0.99,1.01)、[-0.98,1.02)…[8.98,10.98)、[8.99,10.99)、[9,11)，箱组数1001。

^a 此时滚动箱组均值估计等价于谱宽 $h = 1$ 的矩形核函数 (rectangular kernel) 估计

(示例) 滚动箱组均值估计：数据计算表

利用箱组均值估计公式，我们可以计算得到不同箱组的均值估计：

x	bins	sum_ky	sum_k	m1
0.00	[-1,1)	7.1916	8	0.8990
0.01	[-0.99,1.01)	7.1916	8	0.8990
0.02	[-0.98,1.02)	7.1916	8	0.8990
0.03	[-0.97,1.03)	7.1916	8	0.8990
0.04	[-0.96,1.04)	7.1916	8	0.8990

Showing 1 to 5 of 1,001 entries

Previous

1

2

3

4

5

...


201

Next

- 箱组内因变量观测值的求和 $\text{sum_ky} = \sum_{i=1}^n 1\{|X_i - x| \leq h\} \cdot Y_i$
- 箱组的样本数 $\text{sum_k} = \sum_{i=1}^n 1\{|X_i - x| \leq h\}$
- 箱组的均值估计 $\text{m1} = \widehat{m}(x_j), j \in (1, 2, \dots, 1001)$


(示例)滚动箱组均值估计：图形表达

- 根据箱组均值计算值，我们展示在散点图中：



(示例)滚动箱组均值估计：图形表达

- 同样地，可将箱组均值作为对这一箱组条件期望函数CEF的近似：



1.3 核估计：回顾与思考

上述两种箱组均值估计的公式中：

$$\hat{m}(x) = \frac{\sum_{i=1}^n 1\{|X_i - x| \leq h\} \cdot Y_i}{\sum_{i=1}^n 1\{|X_i - x| \leq h\}}$$

- 对条件期望的估计 $\hat{m}(x)$ 结果都呈现一定的锯齿形态 (jagged)，也即估计结果不太平滑 (smoothed)。

1.3 核估计：回顾与思考

思考：



- 为什么估计结果会呈现不太平滑的锯齿形态？
- 能不能让估计结果更加平滑呢？

回答：



- 问题的关键在于上面的估计公式使用了箱组指示函数（可视作为权重） $\sum_{i=1}^n 1 \{ |X_i - x| \leq h \}$ ，而这个权重函数本身是跳跃的。
- 有没有一种办法能够基于平滑的权重函数来计算CEF的估计值呢？

1.3 核估计：概念

核估计 (kernel estimator) : 基于多种类型的核函数 (kernel function) 作为权重函数——可以是连续的，也可以是跳跃的——来估计条件期望函数 $\hat{m}(x)$ 的一种估计方法。

$$\hat{m}_{\text{nw}}(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}$$

- 其中: $K(u)$ 为核函数 (kernel function)

1.3 核估计：特点

$$\hat{m}_{\text{nw}}(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}$$

- 尽管这里使用了核函数来计算权重，但是本质上上述公式还是利用了箱组估计的方法，也即把箱组计算值作为这一箱组的代表值。
- 以上估计方法也被称为**局部常数估计** (local constant estimator) 或**NW估计** (Nadaraya-Watson estimator)
- 容易发现前述箱组均值估计和滚动箱组均值估计都是局部常数估计 (local constant estimator) 的两个特例。

1.3 核估计：核函数定义

定义：若满足如下条件，则可称之为核函数（Kernel function） $K(u)$

- $0 \leq K(u) \leq \bar{K} < \infty$,
- $K(u) = K(-u)$,
- $\int_{-\infty}^{\infty} K(u)du = 1$,
- 对所有的正整数 r 都有 $\int_{-\infty}^{\infty} |u|^r K(u)du < \infty$

定义：正规化核函数（normalized kernel function）需满足

$$\int_{-\infty}^{\infty} u^2 K(u)du = 1$$



- 核函数本质上是一种边界约束的概率密度函数（bounded pdf）
- 核函数是原点对称的，且核函数为非负数（因此可用于权重）

1.3 核估计：常见的正规化核函数 1/2

- 矩形核函数 (Rectangular Kernel) , $R_K = \frac{1}{2\sqrt{3}}$

$$K(u) = \begin{cases} \frac{1}{2\sqrt{3}} & \text{if } |u| < \sqrt{3} \\ 0 & \text{otherwise} \end{cases}$$


- 高斯核函数 (Gaussian Kernel) , $R_K = \frac{1}{2\sqrt{\pi}}$

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right)$$

- 叶氏核函数 (Epanechnikov Kernel) , $R_K = \frac{3\sqrt{5}}{25}$

$$K(u) = \begin{cases} \frac{3}{4\sqrt{5}} \left(1 - \frac{u^2}{5}\right) & \text{if } |u| < \sqrt{5} \\ 0 & \text{otherwise} \end{cases}$$

(示例) 核函数类型



1.3 核估计：常见的正规化核函数 2/2


- 三角核函数 (Triangular Kernel) , $R_K = \frac{\sqrt{3}}{9}$

$$K(u) = \begin{cases} \frac{1}{\sqrt{6}} \left(1 - \frac{|u|}{\sqrt{6}}\right) & \text{if } |u| < \sqrt{6} \\ 0 & \text{otherwise} \end{cases}$$

- 双权核函数 (Biweight Kernel) , $R_K = \frac{5\sqrt{7}}{49}$

$$K(u) = \begin{cases} \frac{15}{16\sqrt{7}} \left(1 - \frac{u^2}{7}\right) & \text{if } |u| < \sqrt{7} \\ 0 & \text{otherwise} \end{cases}$$

(示例) 核函数类型 (续)



1.3 核估计：操作过程

NW核估计（NW Estimator）的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定谱宽 h , 划分出若干箱组（bins）（箱组会有重叠）: $\{b_1, b_2, \dots, b_q\}$

$$b_j = [x_j - h, x_j + h]$$

- 根据样本数据集, 以及 X_i 的实际情况, 计算特定核函数化的权重值:

$$K\left(\frac{X_i - x_j}{h}\right)$$

- 最后计算不同箱组的 Y_i 的均值 $\hat{m}(x_{b_j}), j \in (1, 2, \dots, q)$:

$$\hat{m}_{\text{nw}}(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$$

(示例) 核估计：设定箱组划分规则

下面我们分别设定如下箱组划分规则：

- 设定箱组取值中心点
 $(X = x_i), x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots, 9.95, 9.96, 9.97, 9.98, 9.99, 10.00)$
- 确定核函数类型为高斯核函数^a，谱宽设定为 $h = 1/\sqrt{3}$ 。
- 那么，可以得到箱组区块bins=[-1,1)、[-0.99,1.01)、[-0.98,1.02)…[8.98,10.98)、[8.99,10.99)、[9,11)，箱组数1001。

(示例) 核估计：数据计算表

利用箱组均值核函数估计公式，我们可以计算得到不同箱组的均值估计：

x	bins	sum_ky	sum_k	m2
0.00	[-1,1)	1.9298	2.3571	0.8187
0.01	[-0.99,1.01)	1.9621	2.3952	0.8191
0.02	[-0.98,1.02)	1.9945	2.4336	0.8196
0.03	[-0.97,1.03)	2.0271	2.4722	0.8200
0.04	[-0.96,1.04)	2.0599	2.5109	0.8204

Showing 1 to 5 of 1,001 entries

Previous

1

2

3

4

5


...

201


Next

(示例) 核估计：图形表达

- 同样地，可将箱组均值作为对这一箱组条件期望函数CEF的近似：



(示例) CEF估计：三种估计方法的图形比较



- NW核估计方法相比箱组均值估计和滚动箱组均值估计要更加平滑。

2. 局部回归 (Local Regression)

2.1 箱组线性回归 (Binned Regression)

2.2 滚动箱组回归 (Rolling Regression)

2.3 局部线性回归 (Local Linear Regression)

2.4 局部多项式回归 (Local Polynomial Regression)

引子：从NW估计量说起

在一个局部区域（如 $X = x$ 的领域内），对 $m(x)$ 的 Nadaraya-Watson (NW) 估计量将表现为常函数 (constant function) 形态，此时也称为局部常数估计量 (Local constant estimator)。

- 此时，Nadaraya-Watson (NW) 估计量为一种局部近似，也即当在局部渐近取值 $X \simeq x$ 时， $m(X) \simeq m(x)$

$$Y = m(X) + e \simeq m(x) + e$$

上述模型可以视作为回归方程，我们需要估计得到 $\widehat{m}(x)$ ，也即：

$$\widehat{m}_{\text{nw}}(x) = \operatorname{argmin}_m \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) (Y_i - m)^2$$

- 本质上，以上就是一个 Y 对截距项的加权回归 (Weighted regression) 估计量。

引子：CEF的回归估计方法

事实上，基于箱组原理的CEF估计方法，我们都可以使用回归方法来进行估计，具体包括：

- 箱组线性回归 (binned regression) : 箱组内直接使用OLS回归估计
- 滚动箱组核回归 (NW regression) : 箱组内直接使用OLS回归估计
- 局部线性回归 (Local linear regression) : 箱组内使用加权OLS回归估计
- 局部多项式回归 (Local Polynomial regression) : 箱组内使用多项式的加权OLS回归估计

2.1 箱组线性回归：原理

箱组线性回归 (binned regression) : 箱组内直接使用OLS回归估计

$$Y = m(X) + e \simeq m(x) + e$$

- 上述模型可以视作为回归方程，我们需要估计得到 $\widehat{m}(x)$ ，也即：

$$\widehat{m}_{\text{bin}}(x) = \operatorname{argmin}_m \sum_{i=1}^n \mathbf{1}\{|X_i - x| \leq h\} \cdot (Y_i - m)^2$$

- 因为在箱组内的权重都是一样的，因此可以直接在箱组内的子样本数据里使用OLS回归估计得到

$$\widehat{m}(x) = \widehat{Y}_i \quad (\text{OLS})$$

2.1 箱组线性回归：操作步骤

箱组线性回归（Binned regression）的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定谱宽 h , 划分出若干箱组（bins）：

$$\{b_1, b_2, \dots, b_q\}$$

$$b_j = [x_j - h, x_j + h]$$

- 根据样本数据集, 以及 X_i 的实际情况, 确定数据对 $\{X_i, Y_i\}$ 的箱组归属（子样本）：

$$1 \{ |X_i - x_j| \leq h \}$$

- 然后采用OLS方法计算不同箱组的 Y_i 的拟合值 $\hat{Y}_i = \hat{m}(x) \simeq m(X)$

$$\hat{Y}_i = \hat{\alpha}_0 + \hat{\alpha}_1 X_i$$

- 最后, 我们可以给定任意值 x_i 得到预测的 $\hat{m}(x_i) = \hat{Y}_i | x_i$

(示例) 箱组回归估计：设定箱组划分规则

下面我们分别设定如下箱组划分规则：

- 设定箱组取值中心点 ($X = x_i$), $x_i \in (1, 3, 5, 7, 9)$, 以及带宽 $h = 1$
- 然后得到箱组区块bins=[0,2)、[2,4)、[4,6)、[6,8)、[8,10], 箱组数为5。
- 箱组内的线性回归模型为

$$\hat{Y}_i = \hat{\alpha}_0 + \hat{\alpha}_1 X_i$$

- 基于设定的

$x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots, 9.95, 9.96, 9.97, 9.98, 9.99, 10.00)$ 计算预测值 $\hat{m}(x_i) = \hat{Y}_i | x_i$, 共有 $N = 1001$ 个

(示例) 箱组线性回归：数据计算表

$$\hat{Y}_i = \hat{\alpha}_0 + \hat{\alpha}_1 X_i$$

- 对五个箱组的区块下，我们依次对子样本数据对 (Y_i, X_i) 进行线性OLS拟合，分别得到截距和斜率：

par	bd1	bd2	bd3	bd4	bd5
intercept	0.75	1.45	2.32	0.74	0.72
slope	0.11	-0.19	-0.42	-0.12	-0.09

说明：bd1、bd2等分别代表五个箱组。

(示例) 箱组线性回归：数据计算表

利用箱组均值估计公式，我们可以计算得到不同箱组的均值估计：

bd	my	bins	x	m0
[0,2)	0.8622	[-1.00,1.00)	0.0000	0.7489
[0,2)	0.8622	[-0.99,1.01)	0.0100	0.7500
[0,2)	0.8622	[-0.98,1.02)	0.0200	0.7511
[0,2)	0.8622	[-0.97,1.03)	0.0300	0.7523
[0,2)	0.8622	[-0.96,1.04)	0.0400	0.7534
[0,2)	0.8622	[-0.95,1.05)	0.0500	0.7545


Showing 1 to 6 of 1,001 entries

Previous

- 基于设定的 x 表示 $x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots)$, 共有 $N = 1001$ 个
- 箱组回归估计 $m_0 \hat{m}(x_i) = \hat{Y}_i | x_i$


(示例) 箱组线性回归：图形表达1/2

- 如前，我们设定区隔了5个箱组



(示例) 箱组线性回归：图形表达2/2

- 根据前面计算表的1001个拟合数据对 $(x_i, \hat{m}(x_i))$ ，我们可以得到箱组线性回归估计结果：



2.2 滚动箱组回归：原理

滚动箱组线性回归（rolling regression）：简单地，是通过构建滚动箱组（可能出现箱组重叠状态），然后再对箱组内样本数据直接使用OLS回归估计。此外，容易发现它实际上就是等价于矩形核函数的NW回归（ $h = 1$ ）。

- 此时，Nadaraya-Watson (NW) 估计量为一种局部近似，也即当在局部渐近取值 $X \simeq x$ 时， $m(X) \simeq m(x)$

$$Y = m(X) + e \simeq m(x) + e$$

上述模型可以视作为回归方程，我们需要估计得到 $\widehat{m}(x)$ ，也即：

$$\widehat{m}_{\text{nw}}(x) = \operatorname{argmin}_m \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) (Y_i - m)^2$$

- 本质上，以上就是一个 Y 对截距项的加权回归（Weighted regression）估计量。

2.2 滚动箱组回归：操作步骤

滚动箱组线性回归（Rolling regression）的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定谱宽 h , 划分出若干箱组（bins）（箱组会有重叠）：
 $\{b_1, b_2, \dots, b_q\}$, 其中 $b_j = [x_j - h, x_j + h]$ 。
- 根据样本数据集 X_i 的实际情况, 计算矩形核函数的权重值 ($h = 1$) :

$$K\left(\frac{X_i - x_j}{h}\right)$$

- 然后采用加权OLS方法计算不同箱组下仅含截距项的回归模型的截距系数
 $\widehat{m}(x) \simeq m(X)$

$$Y = m(x) + e$$

(示例) 滚动箱组回归：设定箱组划分规则

下面我们分别设定如下箱组划分规则：

- 设定箱组取值中心点
 $(X = x_i), x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots, 9.95, 9.96, 9.97, 9.98, 9.99, 10.00)$
- 确定核函数类型为矩形核函数^a，谱宽设定为 $h = 1$ 。
- 那么，可以得到箱组区块bins=[-1,1)、[-0.99,1.01)、[-0.98,1.02)…[8.98,10.98)、[8.99,10.99)、[9,11)，箱组数1001。
- 采用加权OLS方法进行拟合，直接计算得到 $\hat{m}(x)$

(示例) 滚动箱组回归：数据计算表

利用箱组均值估计公式，我们可以计算得到不同箱组的均值估计：

bd	bins	x	m1
[0,2)	[-1.00,1.00)	0.0000	0.6397
[0,2)	[-0.99,1.01)	0.0100	0.6444
[0,2)	[-0.98,1.02)	0.0200	0.6492
[0,2)	[-0.97,1.03)	0.0300	0.6539
[0,2)	[-0.96,1.04)	0.0400	0.6587
[0,2)	[-0.95,1.05)	0.0500	0.7266


Showing 1 to 6 of 1,001 entries

Previous

- 基于设定的 x 表示 $x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots)$, 共有 $N = 1001$ 个
- 箱组回归估计 $m1 = \widehat{m}(x_i)$

(示例) 滚动箱组回归：图形表达

- 根据前面计算表的1001个拟合数据对 $(x_i, \hat{m}(x_i))$ ，我们可以得到滚动箱组线性回归估计结果：



2.3 局部线性回归：渐进近似的另一种选择

回顾：Nadaraya-Watson (NW) 估计量的局部近似选择为 $m(X) \simeq m(x)$

局部线性回归 (Local linear regression, LLR) 方法则选择了另一种局部线性近似，也即：

$$m(X) \simeq m(x) + m'(x)(X - x)$$

因此局部线性 (LL) 模型可以表达为：

$$\begin{aligned} Y &= m(X) + e \\ &\simeq m(x) + m'(x)(X - x) + e \\ &= \beta_0 + \beta_1 \cdot (X - x) + e \end{aligned}$$

- 以上模型可以视作为一元线性回归模型，其中 $\beta_0 = m(x); \beta_1 = m'(x)$ 。
- 我们的目标是估计得到 $\widehat{m}(x)$ ，也即上述模型的截距项。

2.3 局部线性回归：矩阵表达式

前述一元线性模型也可以表达为如下矩阵形式：

$$Y \simeq Z(X, x)' \beta(x) + e$$

其中：

$$\begin{aligned}Z(X, x) &= \begin{pmatrix} 1 \\ X - x \end{pmatrix} \\ \beta(x) &= (m(x), m'(x))'\end{aligned}$$

2.3 局部线性回归：最小化问题求解

对于前述渐近近似回归模型，最小化问题可以表达为：

$$\left\{ \widehat{m}_{LL}(x), \widehat{m}'_{LL}(x) \right\} = \underset{\beta_0, \beta_1}{\operatorname{argmin}} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) (Y_i - \beta_0 - \beta_1 (X_i - x))^2$$

我们可以发现两个有意思的结论：



- 当带宽趋于无穷大时 $h \rightarrow \infty$ ，局部线性估计量将趋于全样本OLS估计量 $\widehat{m}_{LL}(x) \rightarrow \widehat{\beta}_0 + \widehat{\beta}_1 x$ 。因为，此时所有样本的权重都会相等。
- 局部线性估计量会同时得到在点 x 处，条件期望函数CEF的估计量 $\widehat{m}(x)$ ，及其斜率 $\widehat{m}'(x)$ 。

2.3 局部线性回归：估计量

以核函数为权重，以及利用加权最小二乘法原理，可以证明局部线性回归的估计量为：

$$\begin{aligned}\hat{\beta}_{\text{LL}}(x) &= \left(\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Z_i(x) Z_i(x)' \right)^{-1} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Z_i(x) Y_i \\ &= (Z' K Z)^{-1} Z' K Y\end{aligned}$$

其中：

- $\mathbf{K} = \text{diag}\{K((X_1 - x)/h), \dots, K((X_n - x)/h)\}$
- \mathbf{Z} 是 $Z_i(x)'$ 的堆栈 (stacked) 形态
- \mathbf{Y} 是 $Y_i(x)'$ 的堆栈形态

2.3 局部线性回归：操作步骤

局部线性回归 (Local Linear regression) 的操作步骤如下：

- 根据计算点 $X = x_j$, 按照特定带宽 h , 划分出若干箱组 (bins) (箱组会有重叠) :
 $\{b_1, b_2, \dots, b_q\}$, 其中 $b_j = [x_j - h, x_j + h]$ 。
- 根据样本数据集 X_i 的实际情况, 计算高斯核函数的权重值 ($h = 1/\sqrt{3}$) :

$$K\left(\frac{X_i - x_j}{h}\right)$$

- 然后采用加权OLS方法计算不同箱组下一元回归模型的截距系数
 $\widehat{m}(x) \simeq m(X)$

$$\begin{aligned} Y &= m(X) + e \\ &\simeq m(x) + m'(x)(X - x) + e \end{aligned}$$

(示例) 局部线性回归：数据计算表

利用局部线性回归估计公式，我们可以计算得到不同箱组的估计：

bd	bins	x	m2
[0,2)	[-1.00,1.00)	0.0000	0.7639
[0,2)	[-0.99,1.01)	0.0100	0.7657
[0,2)	[-0.98,1.02)	0.0200	0.7674
[0,2)	[-0.97,1.03)	0.0300	0.7691
[0,2)	[-0.96,1.04)	0.0400	0.7707
[0,2)	[-0.95,1.05)	0.0500	0.7723


Showing 1 to 6 of 1,001 entries

Previous


- 基于设定的 x 表示 $x_i \in (0.00, 0.01, 0.02, 0.03, 0.04, 0.05, \dots)$, 共有 $N = 1001$ 个
- 箱组回归估计 $m2 = \widehat{m}(x_i)$

(示例) 局部线性回归估计：图形表达

- 根据前面计算表的1001个拟合数据对 $(x_i, \hat{m}(x_i))$ ，我们可以得到局部线性回归估计结果：



(示例) CEF估计：三种回归估计方法的图形比较



- 尽管三种回归估计方法都较好地估计了真实CEF的趋势，但是局部线性回归LLR拟合方法要更平滑。

2.4 局部多项式回归：模型表达

局部多项式回归 (Local Polynomial regression) 模型可以表达为：

$$\begin{aligned} Y &= m(X) + e \\ &\simeq m(x) + m'(x)(X - x) + \cdots + m^{(p)}(x) \frac{(X - x)^p}{p!} + e \\ &= Z(X, x)' \beta(x) + e_i \end{aligned}$$

- 其中：

$$Z(X, x) = \begin{pmatrix} 1 \\ X - x \\ \vdots \\ \frac{(X-x)^p}{p!} \end{pmatrix} \quad \beta(x) = \begin{pmatrix} m(x) \\ m'(x) \\ \vdots \\ m^{(p)}(x) \end{pmatrix}$$

2.4 局部多项式回归：估计量

同样地，以核函数为权重，可以证明局部多项式回归估计量的理论公式为：

$$\begin{aligned}\hat{\beta}_{LP}(x) &= \left(\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Z_i(x) Z_i(x)' \right)^{-1} \left(\sum_{i=1}^n K\left(\frac{Y_i - x}{h}\right) Z_i(x) Y_i \right) \\ &= (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{K} \mathbf{Y}\end{aligned}$$

- 其中 $Z_i(x) = Z(X_i, x)$

2.4 局部多项式回归：特点

- 局部多项式回归LPR具有一般性：



其中有两种特定情形：a) 当 $p = 0$ 时为Nadaraya-Watson回归估计；b) 当 $p = 1$ 时为局部线性回归估计（LL）

- 估计结果需要在阶数 p 和局部平滑谱宽 h 之间寻求平衡。



一方面如果增加多项式阶数 p ，可以改进模型渐近精度，因而倾向选择更大的谱宽 h 。另一方面，增加多项式阶数 p 同时也会导致估计量方差的增大，估计可靠性会降低。

3. 估计效果 (Performance Analysis)

3.1 漐近偏误 (Asymptotic Bias)

3.2 漐近方差 (Asymptotic Variance)

3.3 漐近均方误 (AMSE & AAMSE)

3.4 谱宽选择 (Bandwidth Selection)

3.5 漐近分布 (Asymptotic Distribution)

3.6 方差估计 (Variance Estimation)

3.7 工资案例

3.1 演近偏误：估计量的期望

期望：

$$\mathbb{E} [\widehat{m}_{\text{nw}}(x) \mid \mathbf{X}] = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) \mathbb{E} [Y_i \mid X_i]}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)} = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) m(X_i)}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}$$

3.1 演近偏误：NW和LL估计量的期望

对于局部NW估计量有：

$$\mathbb{E} [\hat{m}_{\text{nw}}(x) \mid \mathbf{X}] = m(x) + h^2 B_{\text{nw}}(x) + o_p(h^2) + O_p\left(\sqrt{\frac{h}{n}}\right)$$

$$B_{\text{nw}}(x) = \frac{1}{2}m''(x) + f(x)^{-1}f'(x)m'(x)$$

- 其中： $B_{\text{nw}}(x) = \frac{1}{2}m''(x) + f(x)^{-1}f'(x)m'(x)$

对于局部线性LL估计量有：

$$\mathbb{E} [\hat{m}_{\text{LL}}(x) \mid \mathbf{X}] = m(x) + h^2 B_{\text{LL}}(x) + o_p(h^2) + O_p\left(\sqrt{\frac{h}{n}}\right)$$


- 其中 $B_{\text{LL}}(x) = \frac{1}{2}m''(x)$

3.1 漐近偏误：定义

漐近偏误 (Asymptotic Bias) : 我们称 $h^2 B_{\text{nw}}(x)$ 和 $h^2 B_{\text{LL}}(x)$ 为漐近偏误。

(示例) 不同谱宽下渐近偏误的表现

- 根据前面计算表的1001个拟合数据对 $(x_i, \widehat{m}(x_i))$ ，我们可以得到滚动箱组线性回归估计结果：



3.2 漐近方差：

漐近方差 (Asymptotic Variance)

$$\hat{m}_{\text{nw}}(x) - \mathbb{E} [\hat{m}_{\text{nw}}(x) \mid \mathbf{X}] = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) e_i}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}$$

$$\text{var}[\hat{m}_{\text{nw}}(x) \mid \mathbf{X}] = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)^2 \sigma^2(X_i)}{\left(\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)\right)^2}$$

3.2 演近方差：

$$\text{var}[\hat{m}_{\text{nw}}(x) \mid \mathbf{X}] = \frac{R_K \sigma^2(x)}{f(x)nh} + o_p\left(\frac{1}{nh}\right)$$

$$\text{var}[\hat{m}_{\text{LL}}(x) \mid \mathbf{X}] = \frac{R_K \sigma^2(x)}{f(x)nh} + o_p\left(\frac{1}{nh}\right)$$

- 核函数 $K(u)$ 的粗糙度 (roughness) 定义为: $R_K = \int_{-\infty}^{\infty} K(u)^2 du$

3.3 漐近均方誤：定义

漐近均方誤（Asymptotic MSE, AMSE）：是估计量 $\widehat{m}(x)$ 的平方漐近偏誤以及漐近誤差二者之和。定义为：

$$\text{AMSE}(x) \stackrel{\text{def}}{=} h^4 B(x)^2 + \frac{R_K \sigma^2(x)}{nhf(x)}$$

3.3 漐近均方誤：連續情形下

漐近积分均方誤(Asymptotic integrated MSE, AIMSE): 类似地定义如下:

$$\begin{aligned}\text{AIMSE} &\stackrel{\text{def}}{=} \int_S \text{AMSE}(x) f(x) w(x) dx \\&= \int_S \left(h^4 B(x)^2 + \frac{R_K \sigma^2(x)}{nh f(x)} \right) f(x) w(x) dx \\&= h^4 \bar{B} + \frac{R_K}{nh} \bar{\sigma}^2\end{aligned}$$

- 其中：

$$\begin{aligned}\bar{B} &= \int_S B(x)^2 f(x) w(x) dx \\ \bar{\sigma}^2 &= \int_S \sigma^2(x) w(x) dx\end{aligned}$$

3.4 谱宽选择：最优谱宽

最小化渐近积分均方误目标下，可以得到最优谱宽（Optimal Bandwidth）：

$$h_0 = \left(\frac{R_K \bar{\sigma}^2}{4 \bar{B}} \right)^{1/5} n^{-1/5}$$

- 此时，随着 $h \sim n^{-1/5}$ ，则有 $\text{AIMSE} [\hat{m}(x)] = O(n^{-4/5})$
- 因此，可以计算出上述最优谱宽下的渐近积分均方误：

$$\text{AIMSE}_0 \simeq 1.65 (R_K^4 \bar{B} \bar{\sigma}^8)^{1/5} n^{-4/5}$$

3.4 谱宽选择：最优谱宽

至此，我们可以得到最优谱宽的理论计算公式：

$$h_0 = \left(\frac{R_K}{4} \right)^{1/5} \left(\frac{\bar{\sigma}^2}{n\bar{B}} \right)^{1/5} \simeq 0.58 \left(\frac{\bar{\sigma}^2}{n\bar{B}} \right)^{1/5}$$

$$\bar{B} = \mathbb{E} [B(X)^2 w(X)] = \mathbb{E} \left[\left(\frac{1}{2} m''(X) \right)^2 \mathbf{1} \{ \xi_1 \leq X \leq \xi_2 \} \right].$$

3.4 谱宽选择：参考谱宽 Rot

Fan and Gijbels(1996)提出了一种经验参考谱宽 (Rule of Thumb bandwidth, ROT) 的计算办法：

$$h_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \hat{B}} \right)^{1/5}$$

- 首先构建先验 q 阶多项式回归模型，并分别估计得到 $\hat{m}(x)$ 及其二阶导 $\hat{m}''(x)$

$$m(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_q x^q + \epsilon$$

- 并使用 \bar{B} 的矩估计量： $\hat{B} = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{2} \hat{m}''(X_i) \right)^2 \mathbf{1}\{\xi_1 \leq X_i \leq \xi_2\}$
- 其次，假定随机干扰项为同方差，也即 $\mathbb{E}[e^2 | X] = \sigma^2$ ，从而可以使用：

$$\bar{\sigma}^2 = \sigma^2 (\xi_2 - \xi_1) \approx \hat{\sigma}^2 (\xi_2 - \xi_1)$$

3.4 谱宽选择：参考谱宽Rot（主要步骤）

参考谱宽rot的主要机选步骤具体包括：

- 步骤1：确定权重取值范围 $w(x) = 1 \{ \xi_1 \leq x \leq \xi_2 \}$
- 步骤2：构建先验 q 阶多项式回归模型（建议为4阶），并分别估计得到 $\hat{m}(x)$ 及其二阶导 $\hat{m}''(x)$

$$m(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_q x^q + \epsilon$$

$$\hat{m}(x) = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \cdots + \hat{\beta}_q x^q$$

$$\hat{m}''(x) = 2\hat{\beta}_2 + 6\hat{\beta}_3 x + 12\hat{\beta}_4 x^2 + \cdots + q(q-1)\hat{\beta}_q x^{q-2}$$

- 步骤3：利用上述估计结果计算

$$\hat{B} = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{2} \hat{m}''(X_i) \right)^2 1 \{ \xi_1 \leq X_i \leq \xi_2 \}$$

3.4 谱宽选择：参考谱宽Rot（主要步骤）

参考谱宽rot的主要机选步骤具体包括：

- 步骤4：计算上述先验q阶多项式回归模型的回归误差方差 $\hat{\sigma}^2$


$$\hat{\sigma}^2 = \frac{\sum \hat{\epsilon}^2}{n - q - 1}$$

- 步骤5：根据上述全部结果计算得到经验谱宽：

$$h_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \hat{B}} \right)^{1/5}$$

(示例) 参考谱宽的计算：数据散点图

- 我们继续使用前述的蒙特卡洛模拟数据集：



(示例) 参考谱宽的计算：多项式回归

下面我们按前述步骤来计算参考谱宽值 h_{rot} :

- 步骤1：根据案例数据集，设定权重取值范围 $\{\xi_1 \leq x \leq \xi_2\} = \{0, 10\}$
- 步骤2：构建多项式回归

$$Y_i = +\beta_1 + \beta_2 X_i + \beta_3 X_i^2 + \beta_4 X_i^3 + \beta_5 X_i^4 + u_i$$

直接使用OLS进行估计，得到估计方程：

$$\begin{aligned}\widehat{Y} &= +0.4943 + 0.6986X_i - 0.2807X_i^2 + 0.0326X_i^3 - 0.0012X_i^4 \\(s) &\quad (0.1521) \quad (0.2015) \quad (0.0802) \quad (0.0119) \quad (0.0006)\end{aligned}$$

进而得到拟合值 $\widehat{m}(x)$ 及其二阶导 $\widehat{m}''(x)$

$$\begin{aligned}\widehat{m}(x) &= +0.4943 + 0.6986x_i - 0.2807x_i^2 + 0.0326x_i^3 - 0.0012x_i^4 \\ \widehat{m}''(x) &= -2 \times 0.2807 + 6 \times 0.0326x_i - 12 \times 0.0012x_i^2\end{aligned}$$

(示例) 参考谱宽的计算：多项式回归

- 拟合值 $\hat{m}(x)$ 及其二阶导 $\hat{m}''(x)$ 以及残差 $\hat{\epsilon}$

多项式回归计算表

mx	mx_q2	epsilon
0.8671	-0.0580	-0.0551
-0.1482	0.0268	-0.3401
-0.0739	0.0489	0.0285
0.7813	-0.0393	0.3009
-0.1368	0.0162	-0.3513
0.9279	-0.1956	0.1830
0.4530	0.0093	-0.2074
0.6082	-0.0107	0.3543

Showing 1 to 8 of 100 entries

Previous

1

2

3

4

5

...

13

Next

(示例) 参考谱宽的计算：结果

- 步骤3：利用上述估计结果计算

$$\hat{B} = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{2} \hat{m}''(X_i) \right)^2 \mathbf{1}\{\xi_1 \leq X_i \leq \xi_2\} = 0.0089$$

- 步骤4：多项式模型的回归误差方差

$$\hat{\sigma}^2 = \frac{\sum \hat{\epsilon}^2}{n - q - 1} = 0.0687$$

- 步骤5：根据上述全部结果计算得到经验谱宽：

$$h_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \hat{B}} \right)^{1/5} = 0.58 \times \left(\frac{0.0687 \times (10 - 0)}{100 \times 0.0089} \right)^{1/5} = 0.5508$$

3.4 谱宽选择：交叉验证谱宽（目标问题）

我们期望选择谱宽，以实现估计量 $\widehat{m}(x, h)$ 最小化积分均方误（Integrated mean-squared error, IMSE），也即：

$$\text{IMSE}_n(h) = \int_S \mathbb{E} [(\widehat{m}(x, h) - m(x))^2] f(x) w(x) dx$$

- 其中 $f(x)$ 为 X 的边际密度（marginal density）
- $w(x)$ 为可积分权重函数（integrable weight function）

3.4 谱宽选择：交叉验证谱宽（可行计算）

上述最小化问题中，偏差值 $(\widehat{m}(x, h) - m(x))$ 可以通过留一法下的预测误差来代替，也即：

$$\tilde{e}_i(h) = Y_i - \tilde{m}_{-i}(X_i, h)$$

因此，上述最小化问题 $IMSE_n(h)$ 的一个可行计算方案可以表达为如下的交叉验证准则函数（Cross-Validation Criterion）：

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \tilde{e}_i(h)^2 w(X_i)$$

3.4 谱宽选择：交叉验证谱宽（准则函数）

对于交叉验证准则函数 (Cross-Validation Criterion) :

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \tilde{e}_i(h)^2 w(X_i)$$

我们可以证明它是去掉一个样本的积分均方误 $IMSE_{(n-1)}(h)$ 加上一个常数项的无偏估计，也即：

$$\mathbb{E}[CV(h)] = \bar{\sigma}^2 + IMSE_{n-1}(h)$$

- 其中: $\bar{\sigma}^2 = \mathbb{E}[e^2 w(X)]$, 它是不依赖于谱宽 h 的。
- 显然, 最小化 $\mathbb{E}[CV(h)]$ 和最小化 $IMSE_{n-1}(h)$ 将是等价的。
- 而且, 当 n 比较大时, 最小化 $IMSE_{n-1}(h)$ 和最小化 $IMSE_n(h)$ 也将是等价的, 二者各自得到的谱宽也是无偏的。

3.4 谱宽选择：交叉验证谱宽（受约束）

另外，为了避免谱宽值选择过小，需要给定约束条件 $h \geq h_\ell$ ，此时：

$$h_{\text{CV}} = \underset{h \geq h_\ell}{\operatorname{argmin}} \text{CV}(h)$$

3.4 谱宽选择：交叉验证谱宽（主要过程）

因此，最优交叉验证谱宽选择的主要过程如下：

- 构建 h 的序贯数值 (grid value) $[h_1, h_2, \dots, h_J]$ ，并评估交叉效用准则函数的最小化取值 $CV(h_j), j \in (1, 2, \dots, J)$ ，从而得到最优谱宽：

$$h_{CV} = \operatorname{argmin}_{h \in [h_1, h_2, \dots, h_J]} CV(h)$$

- 需要注意的是，以上方法得到的谱宽理论上可以是无界的。意味着，交叉验证准则函数 $CV(h)$ 是单调下降的，以至于最优谱宽 $h = \infty$ 。
- 此时，将表明全样本回归估计也可能是一个最优结果。也即，使用全样本数据，NW估计方法有 $\widehat{m}(x) = \bar{Y}$ ；而局部线性估计方法则有 $\widehat{m}(x) = \hat{\beta}_0 + \hat{\beta}_1 x$




3.4 谱宽选择：交叉验证谱宽（计算步骤）

- 步骤1：设定初始值。也即选定一个参考谱宽作为初始值，例如前面提到的经验谱宽 h_{rot} 。
- 步骤2：设定调参谱宽（tuning bandwidth）。也即给定待评估的谱宽范围，及其待评估序贯值（grid value）。
 - 一个经验谱宽范围可供参考： $[h_{rot}/3, 3h_{rot}]$ 。
 - 范围内的待评估序贯值的个数 g 也是需要做出尝试性选择。

(示例) 交叉验证谱宽的计算 : 数据集

- 我们继续使用前述的蒙特卡洛模拟数据集:



(示例) 交叉验证谱宽的计算：规则

- 步骤1：设定经验谱宽 $h_{rot} = 0.5508$ 作为初始值。。
- 步骤2：设定调参谱宽（tuning bandwidth）。
- 一个经验谱宽范围可供参考： $[h_{rot}/3, 3h_{rot}] = [0.1836, 1.6524]$ 。
- 给定范围内的搜寻总数为 $n = 201$ 。则待评估序贯值为
$$h \in (0.1836, 0.1909, 0.1983, 0.2056, 0.2130, \dots, 1.6304, 1.6377, 1.6451, 1.6524)$$

。

(示例) 交叉验证谱宽的计算：NIN方法下的预测误差平方

NIN方法100交叉验证的预测误差平方

id	h	loo	ei_sqr
1	0.1836	loo_001	0.0080
1	0.1836	loo_002	0.1278
1	0.1836	loo_003	0.0017
1	0.1836	loo_004	0.0841
1	0.1836	loo_005	0.1126
1	0.1836	loo_006	0.1153
1	0.1836	loo_007	0.0735
1	0.1836	loo_008	0.0902

Showing 1 to 8 of 20,100 entries

Previous

1

2

3

4

5

...

2,513

Next

^a loo 表示交叉验证留一法，例如 loo_001 表示第1个样本数据不进入局部回归估计。

(示例) 交叉验证谱宽的计算：LL方法下的预测误差平方

LL方法LOO交叉验证的预测误差平方

id	h	loo	ei_sqr
1	0.1836	loo_001	0.0093
1	0.1836	loo_002	0.1267
1	0.1836	loo_003	0.0007
1	0.1836	loo_004	0.0820
1	0.1836	loo_005	0.1150
1	0.1836	loo_006	0.0816
1	0.1836	loo_007	0.0713
1	0.1836	loo_008	0.0815

Showing 1 to 8 of 20,100 entries

Previous

1

2

3

4

5

...

2,513

Next

^a loo 表示交叉验证留一法，例如 loo_001 表示第1个样本数据不进入局部回归估计。

(示例) 交叉验证谱宽的计算 : CV计算表

NW和LL方法下的CV计算表

id	h_tune	cv_NW	cv_LL
1	0.1836	0.0752	0.0737
2	0.1909	0.0751	0.0737
3	0.1983	0.0750	0.0738
4	0.2056	0.0749	0.0738
5	0.2130	0.0748	0.0738
6	0.2203	0.0747	0.0738
7	0.2277	0.0746	0.0738
8	0.2350	0.0744	0.0738

Showing 1 to 8 of 201 entries

Previous

1

2

3

4


5

...

26

Next

(示例) 交叉验证谱宽的计算：谱宽与CV变化



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(示例) 最优谱宽下的估计表

使用不同谱宽下从方法对 $m(x)$ 的估计结果

index	xg	mx_rot	mx_cv
1	0.00	0.7603	0.7648
2	0.05	0.7699	0.7696
3	0.10	0.7785	0.7743
4	0.15	0.7862	0.7789
5	0.20	0.7929	0.7833
6	0.25	0.7989	0.7877
7	0.30	0.8041	0.7921
8	0.35	0.8087	0.7965

Showing 1 to 8 of 201 entries

Previous

1

2

3

4


5

...

26


Next

(示例) 真实的条件期望函数 $m(x)$




$$m(X) = \frac{\sin\left(\frac{\pi}{4} \cdot (X_i - 2)\right)}{\frac{\pi}{4} \cdot (X_i - 2)}$$

(示例)岭方法下使用ROT谱宽估计得到的 $m(x)$




西北农林科技大学
NORTHWEST A&F UNIVERSITY

(示例)岭方法下使用最优CV谱宽估计得到的 $m(x)$



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(示例)岭方法下使用不同谱宽估计得到的 $m(x)$ ：对比



(示例) 模拟数据集

为了更好地进行数据验证，我们将根据如下规则生成蒙特卡洛模拟数据集：

$$m(X) = \frac{\sin(\frac{\pi}{4} \cdot (X_i - 2))}{\frac{\pi}{4} \cdot (X_i - 2)}$$

- 此时，我们具有上帝视角，实际上已经知道数据生成机制（DGP）
- 此时，我们心里面已知真实模型为非线性的

3.5 漐近分布：漐近正态分布

漐近分布 (Asymptotic Distribution)

- 对于局部NW估计：

$$\sqrt{nh} (\widehat{m}_{\text{nw}}(x) - m(x) - h^2 B_{\text{nw}}(x)) \xrightarrow{d} N \left(0, \frac{R_K \sigma^2(x)}{f(x)} \right)$$

- 对于局部线性估计：

$$\sqrt{nh} (\widehat{m}_{\text{LL}}(x) - m(x) - h^2 B_{\text{LL}}(x)) \xrightarrow{d} N \left(0, \frac{R_K \sigma^2(x)}{f(x)} \right)$$

3.5 漸近分布：超平滑情形

$$\sqrt{nh} (\hat{m}_{\text{nw}}(x) - m(x)) \xrightarrow{d} N \left(0, \frac{R_K \sigma^2(x)}{f(x)} \right)$$

$$\sqrt{nh} (\widehat{m}_{\text{LL}}(x) - m(x)) \xrightarrow{d} N \left(0, \frac{R_K \sigma^2(x)}{f(x)} \right)$$

3.6 方差估计：条件方差

$$\sigma^2(x) = \text{var}[Y \mid X = x] = \mathbb{E} [e^2 \mid X = x]$$

- NW方法下条件方差的一个理想估计为：

$$\bar{\sigma}^2(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) e_i^2}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}$$

- NW方法下条件方差的一个可行估计为：

$$\hat{\sigma}^2(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right) \tilde{e}_i^2}{\sum_{i=1}^n K\left(\frac{X_i-x}{h}\right)}.$$

其中 $\tilde{e}_i = Y_i - \hat{m}_{-i}(X_i)$ 为留一法下的预测误差 (leave-one-out prediction error)

3.6 方差估计：直接公式

如前所属，NW方法、LL方法和LP方法的CEF估计可以统一表达为：

$$\begin{aligned}\hat{\beta}(x) &= (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} (\mathbf{Z}' \mathbf{K} \mathbf{Y}) \\ &= (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} (\mathbf{Z}' \mathbf{K} \mathbf{m}) + (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} (\mathbf{Z}' \mathbf{K} \mathbf{e})\end{aligned}$$

- 那么，我们可以直接使用下列条件方差公式：

$$\mathbf{V}_{\hat{\beta}}(x) = \text{var}[\hat{\beta} \mid \mathbf{X}] = (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} (\mathbf{Z}' \mathbf{K} \mathbf{D} \mathbf{K} \mathbf{Z}) (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1}$$

- 其中，我们可以直接使用平方误差 \hat{e}_i^2 或者平方预测误差 \tilde{e}_i^2 ：

$$\widehat{\mathbf{V}}_{\hat{\beta}}(x) = (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} \left(\sum_{i=1}^n K \left(\frac{X_i - x}{h} \right)^2 Z_i(x) Z_i(x)' \tilde{e}_i^2 \right) (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1}$$

3.6 方差估计：渐近公式

更为简洁地，我们也可以使用如下条件方差的渐近公式：

$$\widehat{V}_{\widehat{m}(x)} = \frac{R_K \widehat{\sigma}^2(x)}{nh \widehat{f}(x)}$$

- 其中：

$$\widehat{f}(x) = \frac{1}{nb} \sum_{i=1}^n K\left(\frac{X_i - x}{b}\right)$$

$$\widehat{\sigma}^2(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \tilde{e}_i^2}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}.$$

3.6 方差估计：置信带

逐点置信区间 (Pointwise Confidence Interval)

$$\widehat{m}(x) \pm z_{1-\alpha/2}(n - 1) \cdot \sqrt{\widehat{V}_{\widehat{m}(x)}}$$

$$\widehat{m}(x) \pm 1.96 \sqrt{\widehat{V}_{\widehat{m}(x)}}$$

3.7 工资案例：背景说明

工资案例：



- 案例基于CPS数据集，重点分析其中的子样本数据（黑人、男性、拥有12年受教育程度——高中毕业），样本数为n=762。
- 关注的问题：时均工资的对数 ($y = \log(wage)$) 对职业经历 ($x = experience$) 的非参数回归估计。
- 后面的分析中，我们会重点划定观测窗口为：职业经历（年数）范围为 [0, 40]。因为样本中90%以上的观测对象都落在这个范围之内。

(工资案例) 样本数据集

CPS数据集(n=762)

obs	X	Y
1	18	2.7176
2	-2	1.7525
3	30	2.7940
4	30	2.7940
5	18	2.3587
6	28	2.5998
7	14	2.9565
8	22	3.0053

Showing 1 to 8 of 762 entries

Previous

1

2

3

4

5

...


96

Next

- 样本数据的描述性统计如下：

X.age	Y.earnings
Min. : -2	Min. : -3.1
1st Qu.: 15	1st Qu.: 2.2
Median : 25	Median : 2.5
Mean : 25	Mean : 2.5
3rd Qu.: 34	3rd Qu.: 2.8
Max. : 62	Max. : 4.0

(工资案例) 样本数据散点图



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(工资案例) 参考谱宽的计算：多项式回归

下面我们按前述步骤来计算参考谱宽值 h_{rot} :

- 步骤1：根据案例数据集，设定权重取值范围 $\{\xi_1 \leq x \leq \xi_2\} = \{0, 40\}$
- 步骤2：构建多项式回归

$$Y_i = \beta_1 + \beta_2 X_i + \beta_3 X_i^2 + \beta_4 X_i^3 + \beta_5 X_i^4 + u_i$$

直接使用OLS进行估计，得到估计方程：

$$\begin{aligned}\hat{Y} &= + 2.094395 + 0.030951X_i - 0.000103X_i^2 - 0.000021X_i^3 + 0.000000X_i^4 \\(s) \quad (0.1371) \quad (0.0284) \quad (0.0019) \quad (0.0000) \quad (0.0000)\end{aligned}$$

进而得到拟合值 $\hat{m}(x)$ 及其二阶导 $\hat{m}''(x)$ 及残差 $\hat{\epsilon}$

$$\begin{aligned}\hat{m}(x) &= 2.094395 + 0.030951x_i - 0.000103x_i^2 - 0.000021x_i^3 + 0.000000x_i^4 \\ \hat{m}''(x) &= -2 \times 0.000103 - 6 \times 0.000021x_i + 12 \times 0.000000x_i^2\end{aligned}$$

(工资案例) 参考谱宽的计算：结果

- 步骤3：利用上述估计结果计算

$$\widehat{B} = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{2} \hat{m}''(X_i) \right)^2 \mathbf{1}\{\xi_1 \leq X_i \leq \xi_2\} = 0.00000025$$

- 步骤4：多项式模型的回归误差方差

$$\hat{\sigma}^2 = \frac{\sum \hat{\epsilon}^2}{n - q - 1} = 0.2592$$

- 步骤5：根据上述全部结果计算得到经验谱宽：

$$h_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \widehat{B}} \right)^{1/5} = 0.58 \times \left(\frac{0.2592 \times (40 - 0)}{762 \times 0.000000248} \right)^{1/5} = 5.1442$$

(工资案例) 交叉验证谱宽的计算 : 规则

- 步骤1: 设定经验谱宽 $h_{rot} = 5.1442$ 作为初始值。。
- 步骤2: 设定调参谱宽 (tuning bandwidth) 。
- 一个经验谱宽范围可供参考: $[h_{rot}/3, 3h_{rot}] = [1.7147, 15.4326]$ 。
- 给定范围内的搜寻总数为 $n = 201$ 。则待评估序贯值为
$$h \in (1.7147, 1.7833, 1.8519, 1.9205, 1.9891, \dots, 15.2268, 15.2954, 15.3640, 15.4326)$$
。
。

(工资案例)交叉验证谱宽的计算: CV计算表

岭方法下的CV计算表

id	h_tune	cv_LL
1	1.7147	0.2311
2	1.7833	0.2310
3	1.8519	0.2309
4	1.9205	0.2308
5	1.9891	0.2307
6	2.0577	0.2307
7	2.1263	0.2306
8	2.1949	0.2305

Showing 1 to 8 of 201 entries

Previous

1

2

3

4

5


...

26

Next

NORTHWEST A&T UNIVERSITY

(工资案例) 交叉验证谱宽的计算：谱宽与CV变化



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(工资案例)最优谱宽选择下的估计表

使用不同谱宽下以方法对 $m(x)$ 的估计结果

index	xg	mx_rot	mx_cv
1	0.00	2.2050	2.2153
2	0.20	2.2077	2.2205
3	0.40	2.2102	2.2251
4	0.60	2.2125	2.2292
5	0.80	2.2146	2.2328
6	1.00	2.2166	2.2359
7	1.20	2.2184	2.2386
8	1.40	2.2202	2.2410

Showing 1 to 8 of 201 entries

Previous

1

2

3

4


5

...

26


Next

(工资案例)岭方法下使用ROT谱宽估计得到的 $m(x)$




西北农林科技大学
NORTHWEST A&F UNIVERSITY

(工资案例)岭方法下使用最优CV谱宽估计得到的 $m(x)$



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(工资案例)从方法下使用不同谱宽估计得到的 $m(x)$ ：对比



西北农林科技大学
NORTHWEST A&F UNIVERSITY

(工资案例) 方差估计：获得预测残差

(1) 我们首先可以计算得到LL估计下的预测残差的平方 \tilde{e}_i^2

- 这一步可以直接采用前述的参考谱宽 $h_{rot} = 5.1442$

(工资案例) 方差估计：再次获得参考谱宽

(2) 然后开始计算方差估计下的最优谱宽。这里我们再进行一次参考谱宽的计算流程。

- 构建残差平方的多项式回归模型

$$\tilde{e}_i^2 = +\gamma_0 + \gamma_1 X_i + \gamma_2 X_i^2 + \gamma_3 X_i^3 + \gamma_4 X_i^4 + v_i$$

- 利用ROT公式流程，再次获得参考谱宽

$$hv_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \hat{B}} \right)^{1/5} = 0.58 \times \left(\frac{1.2384 \times (40 - 0)}{762 \times 0.000000300} \right)^{1/5} = 6.7708$$

(工资案例) 方差估计：再次获得最优交叉验证谱宽

(3) 然后开始计算方差估计下的最优谱宽。这里我们再进行一次参考谱宽的计算流程。

- 步骤1：设定经验谱宽 $hv_{rot} = 6.7708$ 作为初始值。。
- 步骤2：设定调参谱宽 (tuning bandwidth)。
- 一个经验谱宽范围可供参考： $[2.0, 40.0]$ 。
- 给定范围内的搜寻总数为 $n = 202$ 。则待评估序贯值为
$$h \in (2.0000, 2.1891, 2.3781, 2.5672, 2.7562, \dots, 39.4328, 39.6219, 39.8109, 40.0000)$$
。
- 步骤3：采用交叉验证留一法，分别遍历计算**NW**估计和**LL**估计下的全部CV值（见后面计算表）
- 步骤4：最小CV值对应的谱宽评估值，则为最优交叉验证谱宽。当然，我们最终发现**NW**估计和**LL**估计下的结果是一样的，都选择了最大边界值 $hv_{CV}(NW) = hv_{CV}(LL) = 40$ 。（见后面的CV比较图）

(工资案例)方差估计: CV值计算表(附表)

NW和LL方法下的CV计算表

id	h_tune	cv_NW	cv_LL
1	2.0000	1.2138	1.2134
2	2.1891	1.2131	1.2125
3	2.3781	1.2126	1.2119
4	2.5672	1.2121	1.2114
5	2.7562	1.2117	1.2110
6	2.9453	1.2114	1.2106
7	3.1343	1.2111	1.2104
8	3.3234	1.2108	1.2102

Showing 1 to 8 of 202 entries

Previous

1

2

3

4

5


...

26

Next

NORTHWEST A&T UNIVERSITY

(工资案例) 方差估计: CV值与谱宽(附图)



- LL估计的CV值在局部上具有最小值, 也即局部最优谱宽约为 $h_{v_{cv}}(LL) \simeq 5$
- 但是从全局来看, 无论是NW估计, 还是LL估计, CV函数值都表现为下降趋势。因此它们都选择了最大边界值 $h_{v_{CV}}(NW) = h_{v_{CV}}(LL) = 40$ 。

(工资案例) 方差估计：计算方差、标准差

(4) 利用前面的平方预测误差，并使用谱宽 $h = 5.1442$ 进行LL估计，最终得到方差和标准差估计值（见后面附表）。

$$\widehat{\mathbf{V}}_{\hat{\beta}}(x) = (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1} \left(\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)^2 Z_i(x) Z_i(x)' \tilde{\mathbf{e}}_i^2 \right) (\mathbf{Z}' \mathbf{K} \mathbf{Z})^{-1}$$

(工资案例)方差估计：计算方差估计值(附表)

从方法下的方差和标准差、置信区间

id	xg	mx	s	s2	lwr	upr
1	0	2.2050	0.1016	0.0103	2.0058	2.4042
2	0.2	2.2077	0.0979	0.0096	2.0159	2.3995
3	0.4	2.2102	0.0944	0.0089	2.0252	2.3952
4	0.6	2.2125	0.0911	0.0083	2.0340	2.3910
5	0.8	2.2146	0.0880	0.0078	2.0420	2.3872
6	1	2.2166	0.0852	0.0073	2.0496	2.3836
7	1.2	2.2184	0.0826	0.0068	2.0565	2.3803
8	1.4	2.2202	0.0802	0.0064	2.0629	2.3774

Showing 1 to 8 of 201 entries

Previous

1

2

3

4

5

...

26


Next

(工资案例) 置信区间和置信带

(5) 进一步计算逐点置信区间 (Pointwise Confidence Interval) (见前面附表), 并得到置信带 (见后面附图)。

$$\begin{aligned}\widehat{m}(x) &\pm z_{1-\alpha/2}(n-1) \cdot \sqrt{\widehat{V}_{\widehat{m}(x)}} \\ \widehat{m}(x) &\pm 1.96 \sqrt{\widehat{V}_{\widehat{m}(x)}}\end{aligned}$$

(工资案例)方差估计：置信区间和置信带(附图)



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.群组分析(Cluster observations)

4.1 基本原理

4.2 成绩案例

4.1 基本原理：模型表达

群组观测(Clustered observations)定义为：观测个体 $i = 1, 2, \dots, n_g$ 分别处在群组 $g = 1, 2, \dots, G$ 内，并可观测到变量对 (Y_{ig}, X_{ig}) 。

- 此时，可以定义模型为：

$$Y_{ig} = m(X_{ig}) + e_{ig}$$
$$\mathbb{E}[e_{ig} | \mathbf{X}_g] = 0$$

其中：

- \mathbf{X}_g 是 X_{ig} 的堆栈形式 (stacked)。
- 并假定群组之间是相互独立的。

4.1 基本原理：矩阵表达

进一步地，我们定义如下：

- \mathbf{X}_g 是 X_{ig} 的堆栈形式 (stacked) 。
- \mathbf{Y}_g 是 Y_{ig} 的堆栈形式 (stacked) 。
- $\mathbf{Z}_g(x)$ 是 z_{ig} 的堆栈形式 (stacked) ， 其中：

$$Z_{ig}(x) = \begin{pmatrix} 1 \\ X_{ig} - x \end{pmatrix}$$

- $\mathbf{K}_g(x) = \text{diag}\left\{ K\left(\frac{X_{ig}-x}{h}\right)\right\}$

4.1 基本原理：LL估计

$$\begin{aligned}\hat{\beta}(x) &= \left(\sum_{g=1}^G \sum_{i=1}^{n_g} K\left(\frac{X_{ig} - x}{h}\right) Z_{ig}(x) Z_{ig}(x)' \right)^{-1} \left(\sum_{g=1}^G \sum_{i=1}^{n_g} K\left(\frac{X_{ig} - x}{h}\right) Z_{ig}(x) Y_{ig} \right) \\ &= \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)^{-1} \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Y}_g \right).\end{aligned}$$

- 其中LL的估计量 $\hat{m}(x) = \hat{\beta}_1(x)$ 等于上述估计的截距项。

4.1 基本原理：删组回归法及其预测误差

为了得到预测误差 (prediction error) , 我们可以采用删组回归法 (delete cluster regression) 进行遍历估计:

$$\tilde{\beta}_{(-g)}(x) = \left(\sum_{j \neq g} \mathbf{Z}_j(x)' \mathbf{K}_j(x) \mathbf{Z}_j(x) \right)^{-1} \left(\sum_{j \neq g} \mathbf{Z}_j(x)' \mathbf{K}_j(x) \mathbf{Y}_j \right)$$

然后得到 $m(x)$ 的估计量 $\tilde{m}_1(x) = \tilde{\beta}_{1(-g)}(x)$, 并进一步得到观测个体 ig 的删组预测误差 (delete-cluster prediction error) :

$$\tilde{e}_{ig} = Y_{ig} - \tilde{\beta}_{1(-g)}(X_{ig})$$

4.1 基本原理：条件方差

与之前类似，我们可以得到条件方差：

$$\mathbf{V}_{\hat{\beta}}(x) = \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)^{-1} \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{S}_g(x) \mathbf{K}_g(x) \mathbf{Z}_g(x) \right) \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)$$

- 其中： $\mathbf{S}_g = \mathbb{E} [\mathbf{e}_g \mathbf{e}'_g | \mathbf{X}_g]$,

因此，上述理论协方差矩阵可以通过 $\mathbf{e}_g \mathbf{e}'_g$ 的估计量 $\tilde{\mathbf{e}}_g \tilde{\mathbf{e}}'_g$ 计算得出，也即：

$$\widehat{\mathbf{V}}_{\hat{\beta}}(x) = \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)^{-1} \left(\sum_{g=1}^G \mathbf{Z}_g(x) \mathbf{K}_g(x) \tilde{\mathbf{e}}_g \tilde{\mathbf{e}}'_g \mathbf{K}_g(x) \mathbf{Z}_g(x) \right) \left(\sum_{g=1}^G \mathbf{Z}_g(x) \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)$$

$\widehat{m}(x)$ 的方差也就是上述估计得到的协方差的第1个对角线元素。

4.1 基本原理：交叉验证准则函数

与前面标准的留一法交叉验证略有不同，群组交叉验证准则函数可以表达为：

$$CV(h) = \frac{1}{n} \sum_{g=1}^G \sum_{i=1}^{n_g} \tilde{e}_{ig}^2$$

此时，最优CV谱宽将出现在上述函数的最小值处：

$$h_{CV} = \underset{h \geq h_\ell}{\operatorname{argmin}} CV(h)$$

4.2 (成绩案例) : 背景说明

成绩案例:



- 案例基于(Duflo, Dupas, and Kremer, 2011)学生排位追踪 (percentile tracking) 对成绩 (testscore) 影响的数据集。其中学生排位追踪为分位数变量 (1-100之间)。我们这里重点分析其中的子样本数据 (女生、实施了学生排位追踪)，样本数为n=1487。
- 关注的问题: 学生排位跟踪 ($x=\text{percentile}$) 对学生成绩 ($y = \text{testscore}$) 的非参数回归估计，并且我们对根据学生所在学校 (school ID) 对样本进行了分组。
- 后面的分析中，我们会重点划定观测窗口为：成绩范围 [0, 40]。非参数估计中我们会采用基于高斯核函数 (Gaussian Kernel) 的局部线性回归LL。

4.2 (成绩案例) 样本数据集

数据集($n=1487$)

obs	schoolid	Y	X
1	430	2.9000	3.2051
2	430	9.7429	12.1795
3	430	13.2071	16.0256
4	430	14.2500	17.3077
5	430	13.8286	18.5897
6	430	8.5071	21.1538
7	430	9.2286	22.4359
8	430	13.5714	26.2820

Showing 1 to 8 of 1,487 entries

Previous

1

2

3

4

5

...

186

Next

- 样本数据的描述性统计（未分群组）如下：

schoolid	Y
Length:1487	Min. : 0
Class :character	1st Qu.: 7
Mode :character	Median :13
	Mean :14
	3rd Qu.:21
	Max. :40

4.2 (成绩案例) 样本数据集：群组描述性统计

学生所在学校的群组描述性统计($n=60$)

obs	schoolid	n	x_mean	x_min	x_max	x_sd	y_mean	y_min	y_max
1	1006	28	55.38	4.94	95.68	28.49	8.61	1.00	22.16
2	1012	21	52.43	7.61	98.91	27.19	13.51	4.03	36.50
3	1014	26	52.76	3.52	99.30	30.63	10.42	1.00	19.76
4	1015	21	53.25	9.17	99.17	27.10	17.87	3.69	31.96
5	1020	22	49.34	8.18	99.09	30.73	17.32	0.86	35.41
6	430	21	43.59	3.21	96.79	28.93	11.48	2.83	30.05
7	432	15	59.52	3.97	96.03	23.88	13.58	4.00	29.33
8	436	21	60.83	14.79	96.48	25.99	15.00	0.26	28.16

Showing 1 to 8 of 60 entries

Previous

1

2

3

4


5

...

8

Next

4.2 (成绩案例) 样本数据散点图



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) 参考谱宽的计算：多项式回归

下面我们按前述步骤来计算参考谱宽值 h_{rot} :

- 步骤1：根据案例数据集，设定权重取值范围 $\{\xi_1 \leq x \leq \xi_2\} = \{0, 100\}$
- 步骤2：构建多项式回归

$$Y_i = +\beta_1 + \beta_2 X_i + \beta_3 X_i^2 + \beta_4 X_i^3 + \beta_5 X_i^4 + u_i$$

直接使用OLS进行估计，得到估计方程：

$$\begin{aligned}\widehat{Y} &= +6.815543 + 0.078095X_i + 0.004483X_i^2 - 0.000100X_i^3 + 0.000001X_i^4 \\(s) \quad (1.2764) \quad (0.1656) \quad (0.0065) \quad (0.0001) \quad (0.0000)\end{aligned}$$

进而得到拟合值 $\widehat{m}(x)$ 及其二阶导 $\widehat{m}''(x)$ 及残差 $\hat{\epsilon}$

$$\begin{aligned}\widehat{m}(x) &= 6.815543 + 0.078095x_i + 0.004483x_i^2 - 0.000100x_i^3 + 0.000001x_i^4 \\ \widehat{m}''(x) &= 2 \times 0.004483 - 6 \times 0.000100x_i^3 + 12 \times 0.000001x_i^2\end{aligned}$$

4.2 (成绩案例) 参考谱宽的计算 : 结果

- 步骤3：利用上述估计结果计算

$$\hat{B} = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{2} \hat{m}''(X_i) \right)^2 \mathbf{1}\{\xi_1 \leq X_i \leq \xi_2\} = 2098.61641815$$

- 步骤4：多项式模型的回归误差方差

$$\hat{\sigma}^2 = \frac{\sum \hat{\epsilon}^2}{n - q - 1} = 66.4390$$

- 步骤5：根据上述全部结果计算得到经验谱宽：

$$h_{\text{rot}} = 0.58 \left(\frac{\hat{\sigma}^2 (\xi_2 - \xi_1)}{n \hat{B}} \right)^{1/5} = 0.58 \times \left(\frac{66.4390 \times (1 - 0)}{1487 \times 2098.616418148} \right)^{1/5} = 6.7463$$

4.2 (成绩案例) 交叉验证谱宽的计算 : 规则

- 步骤1: 设定经验谱宽 $h_{rot} = 6.7463$ 作为初始值。。
- 步骤2: 设定调参谱宽 (tuning bandwidth) 。
- 人为选定谱宽范围: $[4, 20]$ 。
- 给定范围内的搜寻总数为 $n = 202$ 。则待评估序贯值为

$$h \in (4.0000, 4.0796, 4.1592, 4.2388, 4.3184, \dots, 19.7612, 19.8408, 19.9204, 20.0000)$$

◦

4.2 (成绩案例) 交叉验证谱宽的计算 : CV计算表

两种CV方法下的计算表

id	h_tune	cv_LL	cv_LLC
1	4.0000	0.0968	0.0414
2	4.0796	0.0906	0.0366
3	4.1592	0.0848	0.0322
4	4.2388	0.0795	0.0282
5	4.3184	0.0747	0.0247
6	4.3980	0.0703	0.0215
7	4.4776	0.0662	0.0187
8	4.5572	0.0625	0.0162

Showing 1 to 8 of 202 entries

Previous

1

2

3


4

5


...

26

Next



4.2 (成绩案例) 交叉验证谱宽的计算：谱宽与CV变化(对比)



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) 交叉验证谱宽的计算：谱宽与CV变化(对比)

- 为了使得两种方法具有可比较性，此处对CV值做了去最小化的尺度变换，也即 $cv^* = cv - \min(cv)$ 。
- 常规的（未分组）局部线性LL交叉验证最优谱宽结果为12.2786，且CV函数相对比较陡峭；而群组化的（按学校分组）局部线性LL交叉验证最优谱宽结果为6.2289，并且在[5, 11]之间CV函数值表现得比较平稳。

4.2 (成绩案例) CEF $m(x)$ 估计 : 基于群组 CV 最优谱宽 (计算表)

使用不同谱宽下 LL 方法对 $m(x)$ 的估计结果

index	xg	mx_rot	mx_cv
1	0.00	6.5023	6.6031
2	0.50	6.5801	6.6335
3	1.00	6.6580	6.6711
4	1.50	6.7360	6.7155
5	2.00	6.8140	6.7659
6	2.50	6.8920	6.8219

Showing 1 to 6 of 201 entries

Previous

1

2

3

4

5


...

34

Next


- 我们采用群组化的 (按学校分组) 局部线性 LL 交叉验证最优谱宽结果为 6.2289 进行 CEF 估算 $\widehat{m}(x)$

4.2 (成绩案例) CEG $m(x)$ 估计 : 基于常规局部线性 LL 方法




西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) CEG $m(x)$ 估计 : 基于群组局部线性 LL 方法



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) CEF $m(x)$ 估计 : 两种局部线性方法对比



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) 方差估计：计算方差、标准差

(4) 直接使用CEF估计中**群组LL交叉验证最优谱宽^a** $h = 6.2289$ 进行局部线性LL估计，并利用删组法计算得到预测误差 \tilde{e}_g ，并最终分别得到未分组的和群组化的协方差矩阵（见下式），从而得到CEF估计值的方差和标准差（见后面附表）。

$$\widehat{\mathbf{V}}_{\hat{\beta}}(x) = \left(\sum_{g=1}^G \mathbf{Z}_g(x)' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)^{-1} \left(\sum_{g=1}^G \mathbf{Z}_g(x) \mathbf{K}_g(x) \tilde{e}_g \tilde{e}_g' \mathbf{K}_g(x) \mathbf{Z}_g(x) \right) \left(\sum_{g=1}^G \mathbf{Z}_g(x) \mathbf{K}_g(x) \mathbf{Z}_g(x) \right)$$

^a 这里我们没有再次评估条件方差估计中的最优谱宽，而是简单直接地使用了CEF估计的交叉验证最优谱宽。但是我们还是要注意，二者的最优谱宽可以完全不相同！

4.2 (成绩案例) 方差估计：计算方差估计值(附表)

以方法下的方差和标准差、置信区间

id	xg	mx	mxl	s_uc	s2_uc	lwr_uc	upr_uc	s	s2	lwr
1	0	6.6031	5.9789	1.5141	2.2924	3.6355	9.5707	1.6551	2.7392	3.3592
2	0.5	6.6335	6.0585	1.4074	1.9807	3.8751	9.3919	1.5694	2.4631	3.5574
3	1	6.6711	6.1381	1.3087	1.7127	4.1061	9.2362	1.4909	2.2229	3.7489
4	1.5	6.7155	6.2178	1.2178	1.4831	4.3285	9.1024	1.4191	2.0139	3.9340
5	2	6.7659	6.2974	1.1343	1.2867	4.5426	8.9892	1.3536	1.8322	4.1129
6	2.5	6.8219	6.3770	1.0579	1.1191	4.7485	8.8953	1.2939	1.6740	4.2860
7	3	6.8830	6.4567	0.9880	0.9762	4.9464	8.8195	1.2394	1.5362	4.4537
8	3.5	6.9485	6.5363	0.9245	0.8547	5.1365	8.7605	1.1899	1.4158	4.6163

Showing 1 to 8 of 201 entries

Previous

1

2

3

4

5

...

26


Next

4.2 (成绩案例) 置信区间和置信带

(5) 进一步计算群组局部线性估计下的逐点置信区间 (Pointwise Confidence Interval) (见前面附表), 并得到置信带 (见后面附图)。

$$\begin{aligned}\widehat{m}(x) &\pm z_{1-\alpha/2}(n-1) \cdot \sqrt{\widehat{V}_{\widehat{m}(x)}} \\ \widehat{m}(x) &\pm 1.96 \sqrt{\widehat{V}_{\widehat{m}(x)}}\end{aligned}$$

4.2 (成绩案例) 置信区间和置信带 (附图)



西北农林科技大学
NORTHWEST A&F UNIVERSITY

4.2 (成绩案例) 置信区间和置信带 : OLS 回归结果 (附录)

作为比较，我们还简单使用了全样本OLS估计得到估计值（绿色）

- 全局OLS回归模型为

$$Y_i = + \beta_1 + \beta_2 X_i + u_i$$

- 直接使用OLS进行估计，得到估计结果：

$$\begin{aligned}\hat{Y} &= + 5.9789 + 0.1593 X_i \\(s) &\quad (0.4472) \quad (0.0077) \\(t) &\quad (+13.37) \quad (+20.74) \\(over) &\quad n = 1487 \quad \hat{\sigma} = 8.2000 \\(fit) &\quad R^2 = 0.2247 \bar{R}^2 = 0.2242 \\(Ftest) &\quad F^* = 430.35 p = 0.0000\end{aligned}$$

本章参考文献

参考文献 (References) : 1/2

Duflo, E., P. Dupas, and M. Kremer (2011). "Peer Effects, Teacher Incentives, and the Impact of Tracking: Evidence from a Randomized Evaluation in Kenya". In: *American economic review* 101.5, pp. 1739-74.

本章结束

